NumPy

Виртуальное окружение

Но прежде, чем перейдём к основной теме --- есть ещё вещь, которую надо обсудить. Возможно, в этом курсе она не такая уж и важная, но в приличном обществе так делать принято. Я говорю о виртуальном окружении.

Виртуальное окружение --- это среда, изолирующая набор установленных пакетов и версий Python от системной среды и/или от других проектов. Зачем?

1. Разные проекты могут требовать разные версии одних и тех же библиотек. Если устанавливать их без использования виртуальных окружений (т.е. глобально), то вы неизбежно наткнётесь на несовместимость. Как можете догадаться каждый раз удалять и ставить необходимую версию библиотеки для работы с тем или иным проектом --- не самое увлекательное занятие, поэтому используйте виртуальные окружения.
2. При переходе на другую рабочую машину можно быстро воссоздать используемое [на изначальной машине] окружение (с помощью фиксации списков пакетов в `requirements.txt`, например). Опять же, ничего не сломав при этом новой.
3. Большое количество пакетов, скаченных однажды для какой-то мелкой задачки, может захламить систему и привести к конфликтам.
4. Возможность использовать несколько разных версий Python (например, для поддержки legacy проектов).

Более "традиционный" способ создавать виртуальные окружения с помощью терминала (и в этом абсолютно нет ничего сложного), но ввиду демонстративных целей данного курса и отсюда максимального упрощения --- мы сделаем это через VSCode.

1. В правом верхнем углу нажимаем кнопку "Select Kernel" (или "Python 3.x.y", где x, y версия Python).

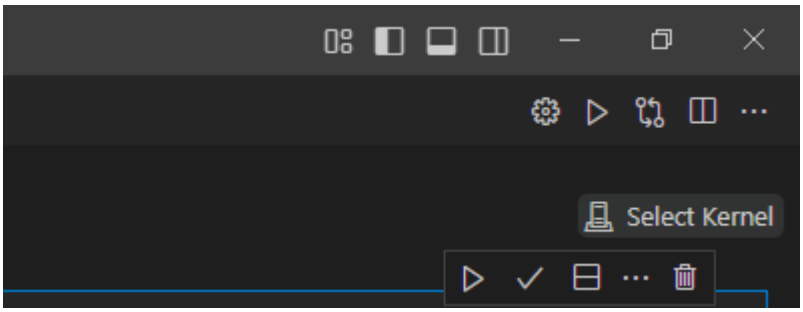

2. В появившемся меню нажимаем "Select Another Kernel..."

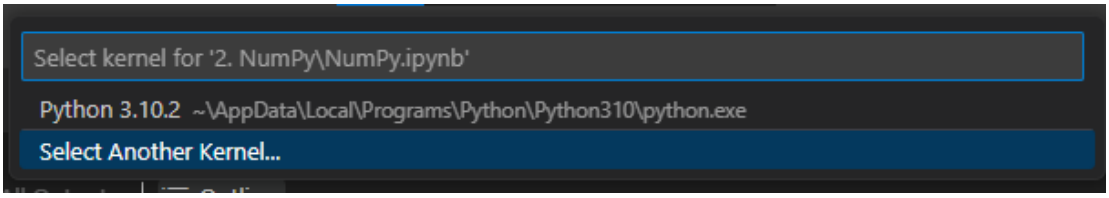

3. Нажимаем "Python Environments..."

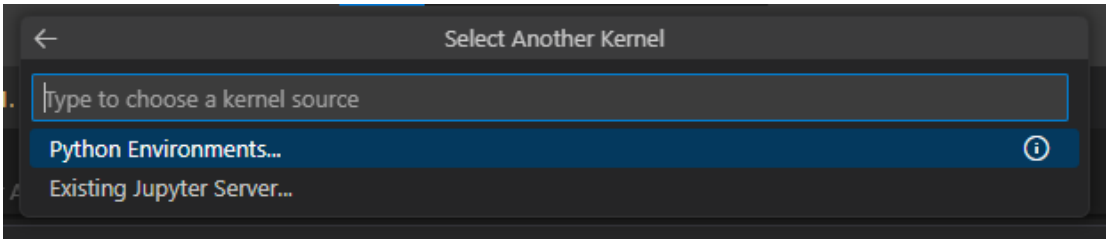

4. "Create New Environment..."

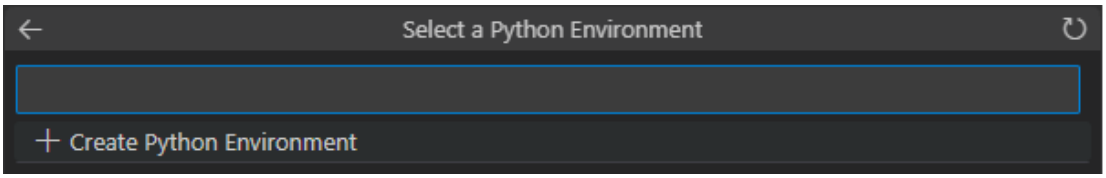

5. "Venv"

> NB: Если вы используете конду, то вместо `.venv` выберете опцию конды. В шаге 8 изменения должны быть аналогичные.

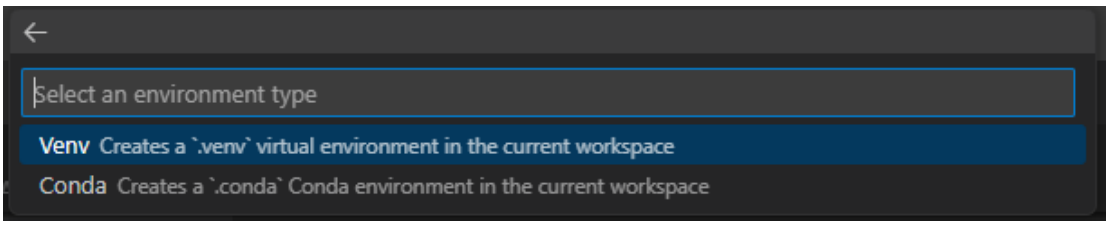

6. "Use Python from `python.defaultInterpreterPath` setting

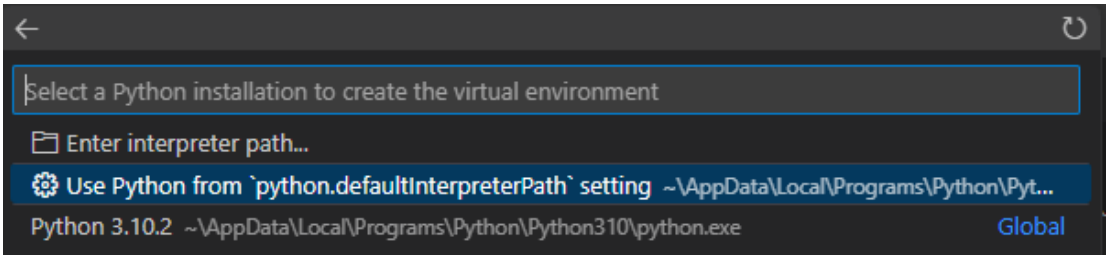

7. Ждём пока окошко в правом нижнем углу не пропадёт.

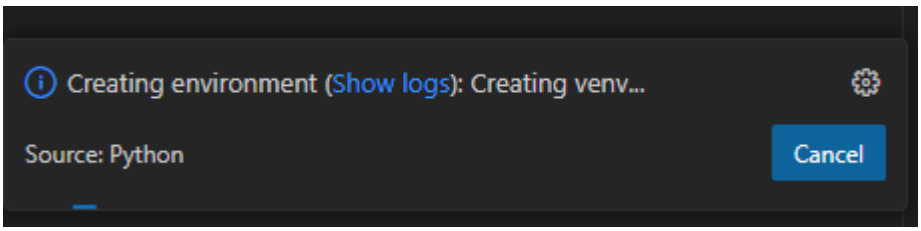

8. Если на месте кнопки "Select Kernel" или что у вас там было в шаге №1 теперь написано ".venv (Python.3.x.y)", то у вас всё удалось. Слева, в обозревателе (напоминание: если он закрыт, то его можно открыть нажав на пиктограму двух файлов в левом верхнем углу или по комбинации клавиш `Ctrl+B`) должна появиться папка `.venv`. Если решите использовать виртуальное окружение, то не забывайте путь к этой папке (пусть она нужна будет для наших учебных целей).

Если вы не хотите использовать виртуальное окружение (зря), но всё равно выполнили все действия, то прежде, чем перейти дальше -- не забудьте вернуться к глобальной версии (нажав на кнопку выбора ядра и выбрав там то, что вам надо). С другой стороны, если вы уже создали виртуальное окружение, то зачем отказываться им пользоваться, если вещь нужная и полезная? Определитесь сами, а мы продолжим.

О NumPy

NumPy --- библиотека для научных вычислений. Плюшки:

- Ndarray --- многомерный массив, оптимизированный для быстрых вычислений (скажите спасибо за это C (языку))
- Замена явных циклов на операции над массивами (векторизация), ускоряет вычисления
- Операции линейной алгебры, генерация псевдослучаных чисел, статистические функции и многое другое.

Зачем? Помимо вышеописанного многие библиотеки для МО и ИИ основаны на NumPy, поэтому нужно знать хотя бы его азы.

Установка

В терминале необходимо выполнить комманду: `pip install numpy` (в случае конды: `conda install numpy`). Если вы используете виртуальное окружение, которое только что создали, то убейте терминал (нажав на пиктограмму мусорного ведра, расположенной на одном уровне с нижними вкладками (среди которых есть вкладка терминала) в правой части) и откройте новый. Ну или закройте/откройте VS Code, как вам удобнее будет.

Если следующая ячейка выполнится корректно, то значит установка прошла успешно.

In [1]:
```
import numpy as np
```

Обратим внимение на часть `as np`. `np` --- общепринятое сокращение для NumPy. Если убрать `as np`, то вместо `np` придётся писать `numpy`, поэтому рекомендуется сокращать и рационально использовать сэкономленное время.

База

Инициализация векторов и матриц

In [51]:
```
vec = np.array([1, 2, 3, 4]) # передаём список
matrix = np.array([          # передаём список списков
    [1, 2, 3],
    [4, 5, 6]
])

print(f'Вектор: {vec}')
print(f'Матрица:\n{matrix}\n')

print(f'Размер вектора: {vec.shape}')
print(f'Размер матрицы: {matrix.shape} (строк, столбцов)')
print(f'Длина вектора: {len(vec)}')
print(f'Длина матрицы: {len(matrix)} (sic!)')
```

```
Вектор: [1 2 3 4]
Матрица:
[[1 2 3]
 [4 5 6]]

Размер вектора: (4,)
Размер матрицы: (2, 3) (строк, столбцов)
Длина вектора: 4
Длина матрицы: 2 (sic!)
```

Обратите внимание на последнюю строку. *Длина* матрицы (и другого многомерного объекта) --- это длина *только первого* измерения, а не общее количество элементов.

Также отметим, что все элементы должны быть одного и того же типа.

In [52]:
```
vec2 = np.array([1, 2.3, 3, 4])
vec3 = np.array([1, True, False, 4])
vec4 = np.array([1, True, False, 4.])
vec5 = np.array([1, 'x', 2, 3.])

template = '{:4} {:20} {:<21}'
print(template.format('vec',  str(vec),  str(vec.dtype)))
print(template.format('vec2', str(vec2), str(vec2.dtype)))
print(template.format('vec3', str(vec3), str(vec3.dtype)))
print(template.format('vec4', str(vec4), str(vec4.dtype)))
print(template.format('vec5', str(vec5), str(vec5.dtype)))
```

```
vec  [1 2 3 4]           int64
vec2 [1.  2.3 3.  4. ]   float64
vec3 [1 1 0 4]           int64
vec4 [1. 1. 0. 4.]       float64
vec5 ['1' 'x' '2' '3.0'] <U32
```

Для любознательных: разобраться в коде выше, что именно и как он делает.

Для всех остальных --- это способ красиво оформить вывод, по сути тоже самое, что и `print(vec, type(vec[0]))`.

Как видим, при передаче разнородных элементов происходит конвертация:

- Дробное среди целых --- все целые становятся дробным
- Булевая среди целых --- `True` становится `1`, а `False` --- `0`.
- Случай с `vec4` разобрать самостоятельно.
- Строка --- конвертирует всё в строку.

Функции инициализации

Функция `zeros` --- инициализирует нулевую матрицу заданного размера (по умолчанию типа `float64`). Обратите внимание на индексацию матрицы (`[x, y]` можно использовать также, как и `[x][y]`).

In [54]:
```
zeros_matrix = np.zeros((2, 3)) # передаём кортеж длин измерений:
                                # (строк, столбцов)
print(zeros_matrix, type([0,0]))
```

```
[[0. 0. 0.]
 [0. 0. 0.]] <class 'numpy.float64'>
```

Тип можно указывать:

In [53]:
```
int_zeros_matrix = np.zeros((2, 3), dtype=int)
print(int_zeros_matrix, int_zeros_matrix.dtype)
```

```
[[0 0 0]
 [0 0 0]] int64
```

Тип данных может поменять.

In [54]:
```
float_zeros_matrix = int_zeros_matrix.astype(np.float64)
print(float_zeros_matrix, float_zeros_matrix.dtype)
```

```
[[0. 0. 0.]
 [0. 0. 0.]] float64
```

`ones` --- матрица, заполненная единицами (*не* единичная матрица).

In [51]:
```
print(np.ones((2, 3)))
```

```
[[1. 1. 1.]
 [1. 1. 1.]]
```

`full` --- создать и заполнить матрицу значением

In [53]:
```
print(np.full((2, 3), 6)) # второй (не третий, его тут нет) аргумент --
                          # желаемое значение
```

```
[[6 6 6]
 [6 6 6]]
```

`identity` и `eye` для создания единичных матриц. `identity` --- прямой как палка: даёшь размер (одним числом, т.к. единичная матрица по определению квадратная), получаешь матрицу.

In [55]:
```
print(np.identity(3))
```

```
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]
```

Функция `eye` интереснее. Она может создавать прямоугольные "единичные" матрицы, но и смещать диагональ вверх или вниз. За это отвечают аргументы `M` (количество столбцов) и `k` соответственно.

In [9]:
```
print('np.eye(3):')
print(np.eye(3))
print('\nnp.eye(3, M=5):')
print(np.eye(3, M=5))
print('\nnp.eye(3, M=2):')
print(np.eye(3, M=2))
print('\nnp.eye(3, k=1):')
print(np.eye(3, k=1))
print('\nnp.eye(3, k=-1):')
print(np.eye(3, k=-1))
```

```
np.eye(3):
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]

np.eye(3, M=5):
[[1. 0. 0. 0. 0.]
 [0. 1. 0. 0. 0.]
 [0. 0. 1. 0. 0.]]

np.eye(3, M=2):
[[1. 0.]
 [0. 1.]
 [0. 0.]]

np.eye(3, k=1):
[[0. 1. 0.]
 [0. 0. 1.]
 [0. 0. 0.]]

np.eye(3, k=-1):
[[0. 0. 0.]
 [1. 0. 0.]
 [0. 1. 0.]]
```

In [11]:
```
print('np.eye(5, M=2, k=-1):')
print(np.eye(5, M=2, k=-1))
```

```
np.eye(5, M=2, k=-1):
[[0. 0.]
 [1. 0.]
 [0. 1.]
 [0. 0.]
 [0. 0.]]
```

Создание последовательностей

`np.arange`

Вспоминаем про `range` из прошлого файла. Если по какой-то причине у вас не было его, то можете обновить с моего github'а. Та же самая идея, только возвращается `ndarray`, а также шаг может быть вещественным.

In [55]:
```
aranged = np.arange(3)
print(aranged)
print(aranged.dtype)
```

```
[0 1 2]
int64
```

In [56]:
```
aranged = np.arange(-2, 3)
print(aranged)
print(aranged.dtype)
```

```
[-2 -1  0  1  2]
int64
```

In [57]:
```
aranged = np.arange(-2, 2, 0.4) # здесь range бы сломался
print(aranged)
print(aranged.dtype)
```

```
[-2.0000000e+00 -1.6000000e+00 -1.2000000e+00 -8.0000000e-01
 -4.0000000e-01 -4.4408921e-16  4.0000000e-01  8.0000000e-01
  1.2000000e+00  1.6000000e+00]
float64
```

In [58]:
```
aranged = np.arange(1.1, -1, -0.4) # здесь range бы сломался
print(aranged)
print(aranged.dtype)
```

```
[ 1.1  0.7  0.3 -0.1 -0.5 -0.9]
float64
```

`np.linspace`

Идея тоже простая. Указываете начальную точку, указываете конечную (здесь **включительно**) и указываете желаемое количество точек, а функция генерирует массив равномерно расположенных точек.

In [21]:
```
np.linspace(-2, 2, 10)
```

Out[21]:
```
array([-2.        , -1.55555556, -1.11111111, -0.66666667, -0.22222222,
        0.22222222,  0.66666667,  1.11111111,  1.55555556,  2.        ])
```

In [23]:
```
np.linspace(3, 2, 10) # в сторону уменьшения тоже можно
```

Out[23]:
```
array([3.        , 2.88888889, 2.77777778, 2.66666667, 2.55555556,
       2.44444444, 2.33333333, 2.22222222, 2.11111111, 2.        ])
```

Для любознательных: разобраться с функцией `logspace`.

Генерация псевдослучайных чисел

Из курса теории вероятности вы знаете, что "случайность бывает разная". Есть такая штука как распределение и от него зависит как "должны вести себя случайные величины".

Для генерации равномерно распределённой псевдойслучайной величина на полуинтервале $[0; 1)$ используется функция `rand` из `numpy.random`. Можно писать так:

In [24]:
```
np.random.rand()
```

Out[24]:
```
0.9547204837595107
```

Можно ввести синоним (как и в случае с `np`, но в там это чуть ли не "обязательная" вещь, то здесь это вкусовщина):

In [27]:
```
import numpy.random as rnd

rnd.rand()
```

Out[27]:
```
0.4162096808724933
```

Можно создать матрицу из псевдослучайных (р.р) чисел, для этого передаём желаемую форму в функцию.

In [28]:
```
rnd.rand(3, 2)
```

Out[28]:
```
array([[0.68702838, 0.53629233],
       [0.24807523, 0.76044603],
       [0.88669286, 0.10913238]])
```

Нормальное распределение, как известно, параметрическое, а значит определяется ими (а точнее мат., ожиданием и дисперсией). Следовательно для того, чтобы сгенерировать псевдослучайную величину, распределённую нормально, нужно передать эти параметры, если этого не сделать, то мы получим псевдослучайную, стандартно распределённую величину ($N(\mu = 0,\ \sigma = 1)$).

In [36]:
```
rnd.normal(3, 4) # \mu = 3, \sigma = 4
```

Out[36]:
```
1.3920549337803085
```

In [37]:
```
rnd.normal(3, 4, (2, 3)) # 2 строки, 3 столбца
```

Out[37]:
```
array([[10.54400637,  3.97854519, -0.02990886],
       [-2.70807928, -1.08869334,  1.81491874]])
```

Для любознательных: понять, что делает вызов кода ниже:

In [47]:
```
rnd.normal((2, 3, 2), (3, 4, 5))
```

Out[47]:
```
array([ 4.36351287,  2.6259662 , -2.86410163])
```

Если нам нужно просто стандартное распределение, то можем воспользоваться функцией `random.randn`, которая работает по тому же принципу, как и `random.rand`.

In [49]:
```
rnd.randn(3,2)
```

Out[49]:
```
array([[ 0.78520433, -1.12349732],
       [-0.45039312, -0.75701072],
       [-0.48099677,  0.3476676 ]])
```

Для любознательных: найти как генерировать другие распределения.

Атрибуты и операции

Мы уже разобрали некоторые атрибуты, как `shape` и `dtype` (тип данных элементов, если вдруг), давайте рассмотрим остальные. Для примера создадим небольшую матрицу.

In [60]:
```
matrix = np.array([
    [1, 2, 3],
    [4, 5, 6]
])

print(f'Число измерений {matrix.ndim}\n'\
      f'Общее число элементов: {matrix.size}')
```

```
Число измерений 2
Общее число элементов: 6
```

`reshape` (важно)

Давайте изменим вид нашей матрицы.

In [77]:
```
matrix_reshaped = matrix.reshape(3, 2)

print('Оригинал:')
print(matrix)
print('\nИзменённая:')
print(matrix_reshaped)
```

```
Оригинал:
[[0 2 3]
 [4 5 6]]

Изменённая:
[[0 2]
 [3 4]
 [5 6]]
```

Важно, данные не копируются, они передаются по ссылке, если изменится новая матрица, старая также изменится.

In [80]:
```
matrix_reshaped[0, 0] = 0
print('Изменённая:')
print(matrix_reshaped)
print('\nОригинальная:')
print(matrix)
```

```
Изменённая:
[[0 2]
 [3 4]
 [5 6]]

Оригинальная:
[[0 2 3]
 [4 5 6]]
```

Сделать "плоским". `ravel` тоже работает со ссылками.

In [82]:
```
array = matrix.ravel()
array
```

Out[82]:
```
array([0, 2, 3, 4, 5, 6])
```

Если нужно скопировать используйте `flatten`.

In [85]:
```
flatted = matrix.flatten()
flatted
```

Out[85]:
```
array([0, 2, 3, 4, 5, 6])
```

Изменения во `flatted` не изменят оригинальный `matrix`.

In [86]:
```
flatted[0] = 1
print(flatted, '\nИсходная матрица:')
print(matrix)
```

```
[1 2 3 4 5 6]
Исходная матрица:
[[0 2 3]
 [4 5 6]]
```

Продемонстрирую, что изменения в `array` (который был создан с помощью `ravel`) изменит оригинальную матрицу.

In [87]:
```
array[0] = 1
print(array, '\nИсходная матрица:')
print(matrix)
```

```
[1 2 3 4 5 6]
Исходная матрица:
[[1 2 3]
 [4 5 6]]
```

Индексация

Индексация одномерных массивов не отличается от индексации в "простом" Python, в том числе и слайсы/срезы, а базовую индексацию многомерных вы видели в этом разделе, так что без повторений двигаемся дальше.

Во-первых, отрицательная идексация многомерных массивов работает.

In [92]:
```
print(matrix[-1, -1])
```

```
6
```

Во-вторых, для кого это было не очевидно, "одномерным индексом" в матрице индексируются строки, например ниже мы получаем первую строку из нашей матрицы.

In [94]:
```
print(matrix[0])
```

```
[1 2 3]
```

Многомерные срезы

С многомерными срезами дела обстоят интереснее.

In [99]:
```
matrix = (rnd.rand(3,3)*20).astype(int) # создаём случайную матрицу размером 3x3
                                        # умножаем каждый её элемент (из
                                        # полуинтервала [0;1)) на 20 и
                                        # конвертируем в целочисленные для
                                        # простоты и красоты
print(matrix)
```

```
[[ 6  8  3]
 [ 6 13  9]
 [ 5  5  4]]
```

In [108…
```
print(matrix[:2]) # первые две строки, все столбцы
```

```
[[ 6  8  3]
 [ 6 13  9]]
```

In [113…
```
print(matrix[-1, :]) # последняя строка
```

```
[5 5 4]
```

In [114…
```
print(matrix[:, -1]) # последний столбец
```

```
[3 9 4]
```

In [111…
```
print(matrix[:, :2]) # все строки, первые два столбца
```

```
[[ 6  8]
 [ 6 13]
 [ 5  5]]
```

In [109…
```
print(matrix[1:]) # последние две строки, все столбцы
```

```
[[ 6 13  9]
 [ 5  5  4]]
```

In [103…
```
print(matrix[:, ::2]) # все строки, каждый второй столбец
```

```
[[6 3]
 [6 9]
 [5 4]]
```

In [110…
```
print(matrix[:, 1:]) # все строки, последние два столбца
```

```
[[ 8  3]
 [13  9]
 [ 5  4]]
```

In [105…
```
print(matrix[::2, :]) # каждая вторая строка, все столбцы
```

```
[[6 8 3]
 [5 5 4]]
```

In [106…
```
print(matrix[::2, ::2]) # каждая вторая строка, каждый второй столбец
```

```
[[6 3]
 [5 4]]
```

In [107…
```
print(matrix[:2, 1:]) # первые две строки, последние два столбца
```

```
[[ 8  3]
 [13  9]]
```

Для любознательных: рассмотреть какие варианты я упустил (также потренироваться на матрицах большего размера).

Булева индексация

Идея проста. Есть массив, есть массив булевых значений того же размера. Применяем одно к другому, забираем только те элементы первого массива, которые по порядку совпали с `True`-элементами булевого массива.

Рассмотрим на примере. Во время зарождения black metal были споры является та или иная группа истинным (true) black metal или нет. Один из критериев --- количество фанатов, если группа была слишком известной, то она не была настоящим black metal. Ниже представлен массив количества фанатов каких-то групп. Будем считать, что если о группе знает больше двух человек (самого исполнителя и его матери), то группа не может считаться настоящим black metal. Найдите количество true black metal групп.

In [116…
```
bm_bands_fans = np.array([3, 1, 2, 5, 6, 1, 6, 7, 4, 9]) # количество фанатов
mask = bm_bands_fans <= 2 # выбираем только те, где количество фанатов не больше
print(len(bm_bands_fans), len(mask)) # демонстрация того, что количество элемент

selected = bm_bands_fans[mask] # выбираем только подходящие
print(len(selected)) # находим количестов подходящих
```

```
10 10
3
```

"Прихотливая" индексация (фанси / фэнси / fancy indexing)

Всё снова довольно просто: массивы могут быть использованы для индексации.

In [ ]:
```
arr = np.arange(11)
print(arr[[1, 6, 7]]) # передаём список индексов
print(arr[[1, 9, 3]]) # "неправильный" порядок допустим

inds = np.array([0, 2, 4])
print(arr[inds])
inds = np.array([0, 8, 4])
print(arr[inds])
```

```
[1 6 7]
[1 9 3]
[0 2 4]
[0 8 4]
```

Для многомерных массивов та же история:

In [6]:
```
matrix = np.array([[1, 2, 3],
                   [4, 5, 6],
                   [7, 8, 9]])

print(matrix[[0, 2], :]) # первая, третья строка
print(matrix[:, [1, 2]]) # второй, третий столбец
```

```
[[1 2 3]
 [7 8 9]]
[[2 3]
 [5 6]
 [8 9]]
```

Изменение части массива

Можно изменять сразу несколько элементов в массиве (мне же не стоит уточнять, что изменить только один элемент также возможно?).

In [7]:
```
arr[1:4] = [100, 50, 75] # напоминаю, что последний индекс не включён
print(arr)
```

```
[  0 100  50  75   4   5   6   7   8   9  10]
```

Операции над массивами и broadcasting (броадкастинг / транслирование)

Арифмитические операции

Операции сложения, вычитания, умножения и деления выполняются поэлементно.

In [2]:
```
a = np.array([1, 2, 3])
b = np.array([4, 5, 6])

print(f'Сложение: {a + b}')
print(f'Вычитание: {a - b}')
print(f'Умножение: {a * b}')
print(f'Деление: {a / b}')
```

```
Сложение: [5 7 9]
Вычитание: [-3 -3 -3]
Умножение: [ 4 10 18]
Деление: [0.25 0.4  0.5 ]
```

Операции со скалярами

In [3]:
```
print(f'a + 10: {a + 10}')
print(f'a * 2: {a * 2}')
```

```
a + 10: [11 12 13]
a * 2: [2 4 6]
```

Поэлементные математические функции

Можно применить одну функцию ко всем элементам массива, без использования функций высшего порядка (см. `map` в прошлом занятии).

In [4]:
```
print(np.sin(a))
print(np.log(a))
print(np.exp(a))
```

```
[0.84147098 0.90929743 0.14112001]
[0.         0.69314718 1.09861229]
[ 2.71828183  7.3890561  20.08553692]
```

Broadcasting

В NumPy можно выполнять арифмитические операции над массивами разных размеров, если они удовлетворяют правилам броадкастинга. Один из случаев был показан выше, взаимодействие массива и скаляра.

Правила

Если размеры массивов не совпадают, NumPy добавляет недостающие оси слева. Здесь `b` из `(3,)` дополнили до `(3, 3)`

In [13]:
```
A = np.random.randint(0, 11, (3, 3))
print('A:')
print(A, A.shape)

b = np.array([10, 20, 30])
print('b: ', b, b.shape)

print(A + b)
```

```
A:
[[0 0 1]
 [6 1 0]
 [7 1 8]] (3, 3)
b:  [10 20 30] (3,)
[[10 20 31]
 [16 21 30]
 [17 21 38]]
```

Если размеры осей различаются, но одна из них равна 1, NumPy расширяет её.

Случай: вектор-столбец `A` + вектор-строка `B`. В данной ситуации `A` из `(3, 1)` дополняется до `(3, 3)`, а `b` из `(3, )` --- до `(3, 3)`.

In [14]:
```
A = np.array([[1],
              [2],
              [3]])
print('A:')
print(A, A.shape)

b = np.array([10, 20, 30])

print('b: ', b, b.shape)

print(A + b)
```

```
A:
[[1]
 [2]
 [3]] (3, 1)
b:  [10 20 30] (3,)
[[11 21 31]
 [12 22 32]
 [13 23 33]]
```

In [18]:
```
A = np.random.randint(0, 11, (1, 3, 1))
B = np.random.randint(0, 11, (3, 1, 2))

S = A + B
print('A: ')
print(A, A.shape)
print('\nB: ')
print(B, B.shape)
print('\nA+B: ')

print(S, S.shape)
```

```
A:
[[[9]
  [8]
  [7]]] (1, 3, 1)

B:
[[[10  6]]

 [[ 5  9]]

 [[ 3  4]]] (3, 1, 2)

A+B:
[[[19 15]
  [18 14]
  [17 13]]

 [[14 18]
  [13 17]
  [12 16]]

 [[12 13]
  [11 12]
  [10 11]]] (3, 3, 2)
```

Для любознательных: разобраться в сложении выше.

Если две оси имеют разные размеры и ни одна из них не равна `1`, то транслирование невозможно.

In [ ]:
```
A = np.random.randint(0, 11, (3, 4))
B = np.random.randint(0, 11, (2, 4))

print(A + B) # получите ошибку
```

Статистические и агрегирующие функции

In [4]:
```
data = np.random.rand(10)*40 - 20
print(data, '\n')

print(f'Сумма: {np.sum(data)}')
print(f'Среднее значение: {np.mean(data)}')
print(f'Минимум: {np.min(data)}')
print(f'Максимум: {np.max(data)}')
print(f'Медиана: {np.median(data)}')
print(f'Стандартное отклонение: {np.std(data)}')
print(f'Дисперсия: {np.var(data)}')
```

```
[ -8.68839584 -18.01410588  17.60733643 -11.92741934   0.22396282
  14.3263759   -9.72140157 -11.68658634  12.32018497   5.08951664]

Сумма: -10.470532226879673
Среднее значение: -1.0470532226879672
Минимум: -18.014105880296935
Максимум: 17.60733642524906
Медиана: -4.23221650981284
Стандартное отклонение: 12.063921204641266
Дисперсия: 145.53819483179316
```

Оси для многомерных массивов

Можно вычислять статистики по разным осям с помощью аргумента `axis`.

In [2]:
```
matrix = np.array([[ 1,  2,  3],
                   [ 4,  5,  6],
                   [ 7,  8,  9],
                   [10, 11, 12]])

print(f"Сумма всей матрицы: {np.sum(matrix)}")
print(f"Сумма по столбцам: {np.sum(matrix, axis=0)}")
print(f"Сумма по строкам: {np.sum(matrix, axis=1)}")
```

```
Сумма всей матрицы: 78
Сумма по столбцам: [22 26 30]
Сумма по строкам: [ 6 15 24 33]
```

Т.е. при `axis=0` операции выполняются по столбцам (и длина такая сколько в матрице столбцов), при `axis=1` операции выполняются по строкам (длина результата равна количеству строк).

Кумулятивные функции

Кумулятивная сумма часто встречается в анализе временных рядов.

In [2]:
```
data = np.array([1, 2, 3, 4])

print(f'Кумулятивная сумма: {np.cumsum(data)}')
print(f'Кумулятивное произведение: {np.cumprod(data)}')
```

```
Кумулятивная сумма: [ 1  3  6 10]
Кумулятивное произведение: [ 1  2  6 24]
```

Перцентили

Напомню, что нулевой процентиль --- минимум, процентиль больше нуля, кратный 25 --- это квартиль, 50-процентиль --- медиана (и второй квартиль, как было сказано ранее), 100-процентиль --- максимум (и четвёртый квартиль).

In [4]:
```
data = np.arange(1000)/10

print(f'1-процентиль {np.percentile(data, 1)}')
print(f'25-процентиль (первый квартиль) {np.percentile(data, 25)}')
print(f'50-процентиль (медиана) {np.percentile(data, 50)}')
print(f'90-процентиль {np.percentile(data, 90)}')
```

```
1-процентиль 0.999
25-процентиль (первый квартиль) 24.975
50-процентиль (медиана) 49.95
90-процентиль 89.91000000000001
```

Пример повеселее, где показана разница между медианой и средним.

In [6]:
```
data = np.arange(70) * np.random.random(70)

print(data, '\n')
print(f'1-процентиль {np.percentile(data, 1)}')
print(f'25-процентиль (первый квартиль) {np.percentile(data, 25)}')
print(f'50-процентиль (медиана) {np.percentile(data, 50)}')
print(f'Среднее {np.mean(data)}')
print(f'90-процентиль {np.percentile(data, 90)}')
```

```
[ 0.          0.90240344  1.45800022  0.27630902  2.45479283  4.53236199
  4.76035066  6.08668048  6.24310833  3.07854606  1.09721717  8.02802214
  7.78671296  2.77472397  3.49308003  7.15357399  7.53382074  6.2716958
 15.37760631  8.97698995 10.84120226  4.62974171 21.80422507 14.14941728
  8.2736367  17.44793406 16.00307578 17.02434333 12.30460855 26.9649619
 10.65394754 13.22335023 24.20212244  9.11680323 11.19105833  0.45537069
  3.95939517 30.90864483  3.28880964 28.93492207 20.04184068  0.90121968
  1.21737773  3.57577042 13.65478081 33.34732945 30.34325202 17.51824827
 26.66517452 26.40509528 13.24023738  0.49492286 46.20234841  0.20573366
 37.24059624 49.45484384 11.23379797  9.73480527  5.78573963 46.33901959
 31.5338908  21.40555045  7.53791919 59.56995659 53.1698122  56.80984754
 50.01141362 66.15301377 47.47233173 14.22637746]

1-процентиль 0.14195622717554618
25-процентиль (первый квартиль) 4.556706921508723
50-процентиль (медиана) 11.016130293379126
Среднее 16.930797342524045
90-процентиль 46.45235080353714
```

NaN

В статистике часто попадаются недостающие данные (NaN, N/A, null и другие способы их записи), из-за которых ломаются обычные вычисления. Вообще тактика работы с пропущенными данными зависит от конкретной задачи и объёма доступных данных, иногда их можно просто проигнориорвать, а иногда [для того чтобы проигнорировать] придётся выкинуть большую часть данных, что совершенно недопустимо (но опять же всё зависит от конкретного случая). По тактике устранения пропусков эмпирические правила, но нет конкретных правил, что делать, разве что **не нужно** делать. Ниже пример данных с пропуском.

In [5]:
```
data = np.array([1, 2, np.nan, 4, 5])
print(data)
```

```
[ 1.  2. nan  4.  5.]
```

Если мы их просто просуммируем, то получим NaN (т.е. потеряем пользу от всех данных).

In [6]:
```
print(np.sum(data))
```

```
nan
```

В NumPy есть функции, которые игнорируют отсутствующие данные (но опять же, это не всегда правильный метод).

In [7]:
```
np.nansum(data)
```

Out[7]:
```
np.float64(12.0)
```

Для любознательных: найти и прочитать другие "nan"-функции.

Коэффициенты корреляции и ковариации

In [11]:
```
x = np.arange(5)
y = np.arange(0, 10, 2)

print(f'x: {x}')
print(f'y: {y}')
print()
print(f'Коэффициент корреляции:\n{np.corrcoef(x, y)}')
print()
print(f'Ковариация:\n{np.cov(x, y)}')
```

```
x: [0 1 2 3 4]
y: [0 2 4 6 8]

Коэффициент корреляции:
[[1. 1.]
 [1. 1.]]

Ковариация:
[[ 2.5  5. ]
 [ 5.  10. ]]
```

Для любознательных

(напоминание, ссылки почему-то работают только в html и pdf версии, VS Code не хочет)

1. Здесь
2. Здесь
3. Здесь
4. Здесь
5. Здесь
6. Здесь

7. Здесь